

Exam Cloner

资源感知的 AI 考试备考系统

王语诺 刘睿淇

香港科技大学（广州）

2026 年 7 月 24 日 · CCF Computility 2026

第三届 CCF 算力网系统与应用大赛

目录

1. 问题与动机
2. 解决方案概览
3. 系统架构
4. 核心技术创新
5. 算力感知与资源调度
6. 演示与部署
7. 工程质量与测试
8. 总结与展望

痛点：考试备考的三重困境

材料多，题目散

课程 PDF 累积成堆，知识点分散在历年试卷、作业、课件中，手动整理耗时且易遗漏。

题海低效，缺乏反馈

刷题缺乏个性化，薄弱点无法精准定位；主观题无人批改，错题反复犯。

算力资源不稳定

大模型服务可能不可用、限流或延迟波动；单一依赖导致学习中断，体验割裂。

核心挑战：在**算力资源波动**的环境下，如何提供**稳定、个性化、有深度反馈**的备考体验？

Exam Cloner: 资源感知的 AI 备考系统

上传课程材料 → AI 解析建题库 → 克隆考试风格生成模拟卷
→ 自适应练习 + LLM 深度批改 → 错题回流复习

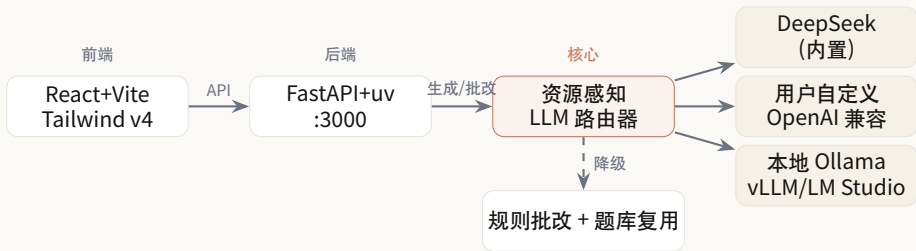
四大功能支柱

- 考试风格克隆: 从试卷/作业提取风格画像
- 自适应练习: SM-2 间隔重复 + 薄弱点调度
- 全题型 LLM 批改: 含结构化深度反馈
- 模拟考试: 可配题型/难度分布, 自动保存

资源感知差异化

- 多模型路由: DeepSeek / Ollama / vLLM / 本地
- 降级容错: 规则批改 + 题库复用兜底
- 熔断器: 3 次失败自动隔离 60 秒
- 算力中心: 实时遥测路由证据可见

系统架构总览



单进程部署 · JSON 原子存储 · 浏览器侧密钥 · SSRF 防护 · 中英文双语

创新一：资源感知 LLM 路由

六级路由优先级（算力网核心）

1. 规则批改：MCQ / 判断题本地确定性判定（零算力）
2. 题库复用：命中已存题目直接返回（零算力）
3. 用户选定 **provider**：用户配置的健康端点优先
4. 管理员本地 **provider**：Ollama / vLLM 等内网服务
5. 内置 **provider**：DeepSeek 兜底（允许 fallback 时）
6. 显式降级：无可用 provider 时返回未批改，不误判

容错机制

- 每-provider 并发上限 + 超时
- 3 次连续失败 → 熔断 60 秒
- 探测成功 → 闭合熔断器
- 重试有界，避免重复计费

安全与隐私

- 用户密钥仅存浏览器，请求级附带
- 用户 URL 禁止内网/回环（防 SSRF）
- 管理员本地端点经环境变量配置
- 遥测不记录密钥与完整 prompt

创新二：SM-2 自适应学习引擎

算法核心

SM-2 间隔重复：基于连续答对次数与难度，动态调度复习间隔。

持久化 ease_factor：每个知识点维护独立难度系数。

Beta 先验：冷启动用 Beta 分布平滑初始评分。

due-concept 调度：优先推送到期薄弱知识点。

数据流

1. 答题 → LLM 批改 → 更新掌握度
2. 误答 → 加入错题本
3. 错题 → 间隔重复调度
4. 模拟考错题 → 一键导入练习

效果：客观题零算力即时反馈 · 主观题 LLM 深度批改 · 薄弱点自动浮现 · 复习间隔科学化

创新三：考试风格克隆与全题型批改

考试风格克隆

- pdfplumber 提取 + LLM 结构化解析
- 从试卷/作业聚合风格画像
- 生成时 few-shot 注入 3 道参考题
- 题型/难度分布可调（滑块）
- 题库/AI 生成比默认 80/20

全题型 LLM 批改

支持五种题型：

- 选择题 / 判断题（规则批改）
- 简答题 / 计算题 / 论述题（LLM）

结构化反馈：

- **correct** 是否正确
- **missing_steps** 缺失步骤
- **wrong_concepts** 错误概念
- **suggestion** 改进建议

算力中心：路由证据可视化

为什么需要算力中心？

算力网应用的核心是**异构资源协同**。我们让每一次模型调用的路由决策、延迟、成败**对用户可见**，而非黑盒。

实时遥测

- 当前路由模式 (hybrid / degraded)
- 各 provider 健康、延迟、熔断状态
- 请求成功率、缓存/规则节省次数
- 最近 20 条路由轨迹 (含 fallback)

用户可操作

- 添加/测试/移除公开兼容端点
- 重新探测所有 provider
- 故障切换演练：零成本模拟失败
- GPU 状态如实显示” 硬件验收待定”

遥测有界 (500 条环形缓冲) · 重启重置 · 不记录密钥与 prompt

部署与演示

部署环境

- 平台: HKUST(GZ) Campus AI (GPUUnion)
- 单进程 FastAPI 监听:3000
- base path /apps/exam-clone/
- 持久数据:
/mydata/exam-cloner-data/
- 容器无 GPU, 约 2 核 4GiB

访问地址

`gpunion.hkust-gz.edu.cn/apps/exam-clone/`
现场可演示

演示流程 (7 步)

1. 切换中英文, 载入演示课程
2. 打开算力中心, 查看 provider 状态
3. 测试用户自定义端点
4. 答客观题, 查看模型调用记录
5. 批改主观题, 展示 provider 与延迟
6. 运行故障切换演练
7. 回 Dashboard, 查看薄弱点与节省

工程质量与安全

代码规模

- 后端 **3,082** 行 Python (13 路由 + 9 服务)
- 前端 **3,711** 行 TypeScript (8 页面 + 组件)
- 测试 **830** 行 (引擎/API/算力/批改)

数据安全

- 原子写入 + 线程锁 `mutate()`
- 文件名 `os.path.basename` 消毒
- 用户隔离 `X-User-Id` 全链路

竞赛正确性审计

- 所有权校验 (上传/提交/重试)
- 考试提交幂等 + 单次使用
- 错题导出幂等 (忽略批改失败)
- SSRF 校验 + 重定向目标校验
- 超时/熔断/fallback 覆盖

近期稳定性修复

- 竞态防护 (`AbortController`)
- `Toast` 定时器泄漏清理
- `localStorage` 安全封装
- 导航 `sticky` + 排序跳动修复

总结与展望

已完成

资源感知 LLM 路由 · SM-2 自适应 · 考试风格克隆 · 全题型 LLM 批改 · 算力中心可视化 · 中英文双语 · 已部署运行

创新点回顾

- 资源感知路由：算力网使能的 AI 应用
- 降级容错：无 GPU 仍可用
- 路由证据可见：非黑盒
- 全题型深度反馈

未来展望

- 多模态题目（图/公式/手写）
- GPU 本地推理接入（硬件验收后）
- 分布式存储替代 JSON
- 跨课程知识图谱
- 更多算力平台适配

谢谢！

欢迎提问与演示

Exam Cloner

王语诺 · 刘睿淇 · HKUST(GZ)

gpunion.hkust-gz.edu.cn/apps/exam-clone/